

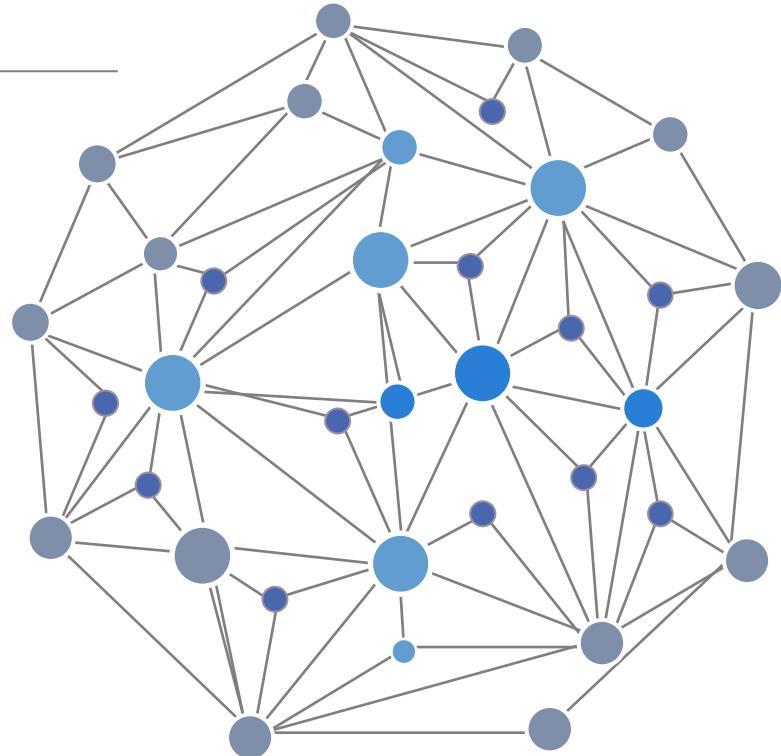
Web 程序设计

第三讲 XML 标准基础

福州大学 计算机与大数据学院

软件工程系 陈昱

2021-11



什么是 Web 标准?

Web 标准是一些规范的集合，是由**W3C**和其他的标准组织共同制定的，用以创建和解释基于 Web 的内容的**规范**

结构化语言

- * HTML (超文本置标语言) 4.01
- * XHTML (可扩展超文本置标语言) 1.0
- * XHTML 1.1
- * XML (可扩展置标语言) 1.0 1.1

表现类语言

- * CSS (层叠式样式表) Level 1
- * CSS Level 2 revision 1
- * CSS Level 3 (正在开发中)
- * MathML (数学置标语言)
- * SVG (矢量图形语言)

对象模型

- * DOM (文档对象模型) Level 1
- * DOM Level 2
- * DOM Level 3 Core

脚本语言

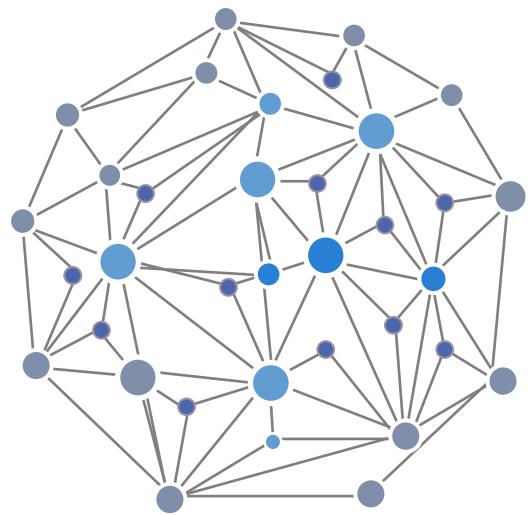
- * ECMAScript 262 (JavaScript的标准化版本)

XML Fundamental

- 置标语言
- 什么是 XML
- XML 文件的组成
- 文档类型定义 DTD
- XML 命名空间 Namespace
- XML 与 HTML 的比较

```
<?xml version="1.0" e
<quiz>
  <question>
    Who was the forty-second
    president of the U.S.A.?
  </question>
  <answer>
    William Jefferson Clinton
  </answer>
  <!-- Note: We need to add
       more questions later.-->
</quiz>
```

XML



置标语

Markup Language

置标语言

- 置标语言，一种用来给文本**添加标记**的语言
- 比如 HTML，它描述了一系列**标记**，每个标记表明了**一定的信息**（语义或是表现的）

Sample 1

- 标记

的含义是要求 HTML 浏览器这段文本表示一个段落
- 标记**的含义是告诉浏览器这段文本需要强调**
- <p>Hello,World</p>

Hello,Wolrd

Sample 2

下面这一段 HTML 代码显示了一个客户联系信息列表：

```
<ul>
<li>张三</li>
  <ul>
    <li>用户ID: 001</li>
    <li>公司: A 公司</li>
    <li>EMAIL: zhang@some.com</li>
    <li>电话: (123) 456789</li>
    <li>地址: 五街 1234 号</li>
    <li>城市: 福州市</li>
  </ul>
</ul>
```

Sample 2



- 张三
 - 用户ID: 001
 - 公司: A 公司
 - EMAIL: zhang@some.com
 - 电话: (123) 456789
 - 地址: 五街 1234 号
 - 城市: 福州市

“置标” Markup

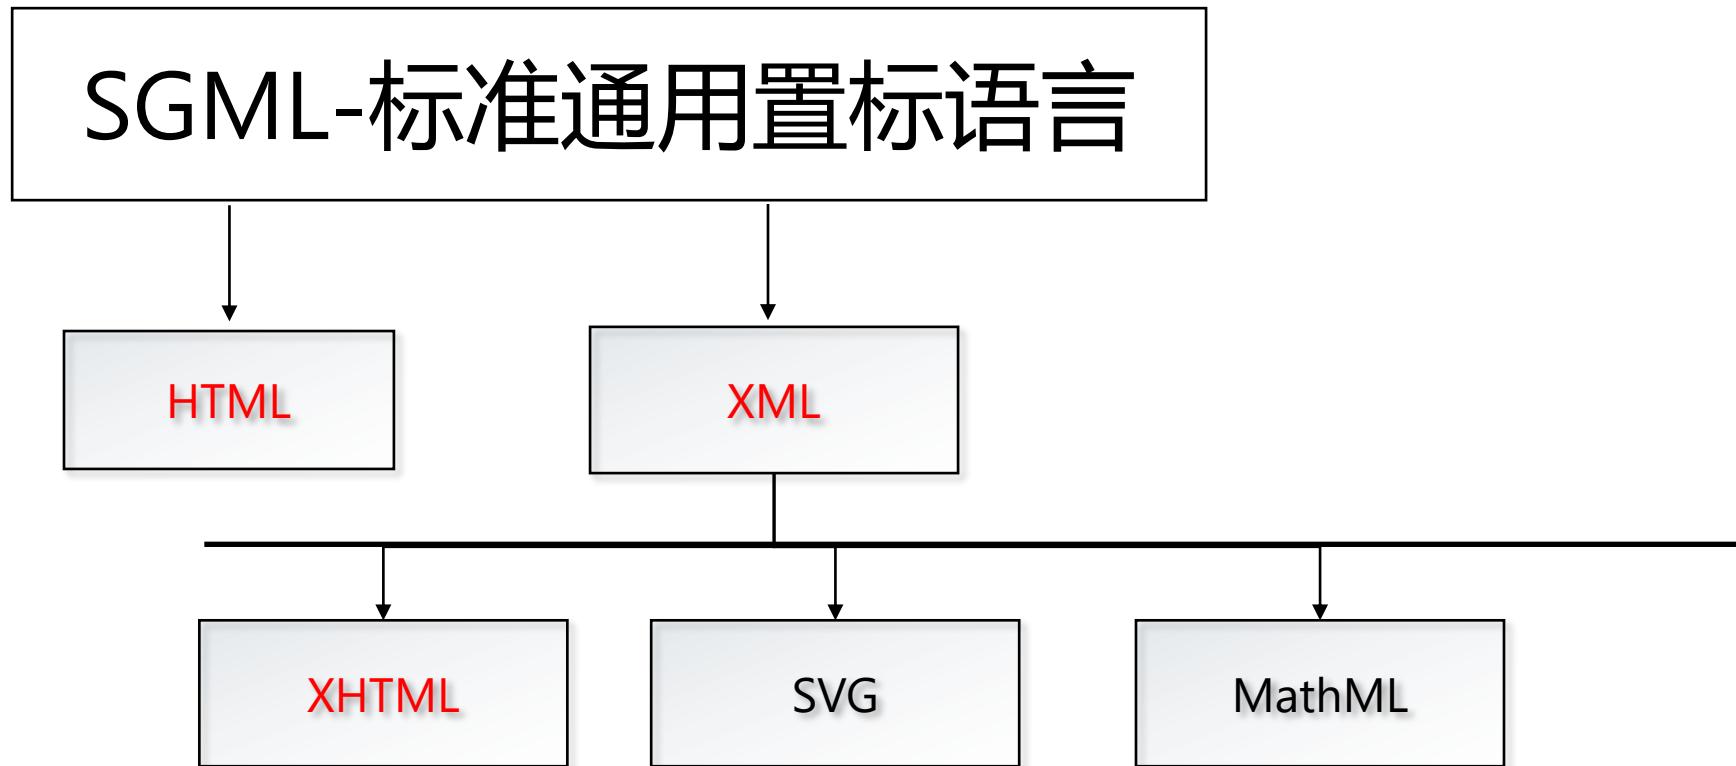
- “置标”的精确定义是：
就数据本身的信息对数据进行编码的方法
- “置标”的概念在现实生活中很常见
 - 比如用笔在课本上划重点

置标语言的定义方式

- 当我们需要通过标记将有用的信息告知人或是计算机时，需要定义两件事情：
- 首先，我们必须有一个标准，用它来描述**什么是标记** (在HTML中为**<tag>**)
- 其次，我们还要有一个标准描述**每个标记的具体含义** (在HTML规范中定义)

置标语言家族一览

- **SGML**, 鼻祖, 元语言 (Meta Language)
- **HTML**, 第一个 Web 置标语言

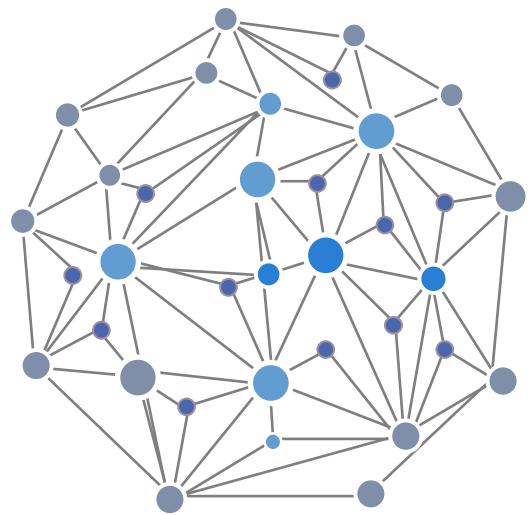


HTML 演化

- HTML 1 (Berners-Lee, 1990): 非常简单，有限的多媒体
 - in 1993, Mosaic 浏览器添加了一些新特性 (比如图像)
- HTML 2.0 (IETF, 1995): 试图标准化这些新特性, 但是 ...
 - 1995-97, Netscape & IE 浏览器大战
- HTML 3.2 (W3C, 1997): 尝试制定统一的标准
 - 但跟不上一些新技术, 如 Java Applets & 流媒体
- HTML 4.01 (W3C, 1999): 后来十五年的正式标准
- HTML 5 (W3C & WHATWG): 已正式发布

早期 HTML 的局限性

1. 逐渐成为描述信息显示的工具
 - 数据搜索不易，搜索引擎无法理解
2. 浏览器大战导致浏览器兼容性
 - 标记越来越多
3. 可扩展性差
 - 无法适应各行各业的特殊要求（数学，化学）
4. 书写时缺乏严格的语法检查机制
 - 内部条理性差



XML

可扩展置标语言

XML

- XML 是 eXtensible Markup Language (可扩展置标语言) 的简写
- 和 HTML 一样, XML 同样来源于 SGML, 但 XML 也是一种能定义其他语言的语言
 - XML 是 SGML 的子集
 - XML 也是元语言

XML 的版本

- 1998年2月10日 XML 1.0
 - 2008年11月26日 XML 1.0 (Fifth Edition)
- 2004年2月4日 XML 1.1
 - 2006年8月16日 XML 1.1 (Second Edition)
- 目前推荐使用的是 **XML 1.0**
 - 如果不需要 1.1 的新特性的话
- 参见 <http://www.w3.org/TR/xml/>

XML 的最大优势 - eXtensible

- 回顾刚才的 HTML 客户信息列表
- 尽管这也是一个存储、显示数据的可行的方法，它的效率和能力却非常有限
 - 数据的显示方式被固定了
 - 在这些数据中寻找信息困难
 - 提取数据困难，HTML 标记对数据理解无帮助

Sample: 客户联系信息列表

下面这一段 HTML 代码显示了一个客户联系信息列表：

```
<ul>
<li>张三</li>
  <ul>
    <li>用户ID: 001</li>
    <li>公司: A 公司</li>
    <li>EMAIL: zhang@some.com</li>
    <li>电话: (123) 456789</li>
    <li>地址: 五街 1234 号</li>
    <li>城市: 福州市</li>
  </ul>
</ul>
```

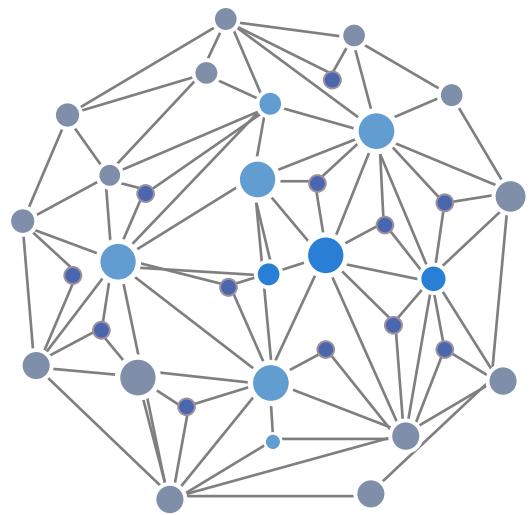
XML Solution

```
<联系人列表>
  <联系人>
    <姓名>张三</姓名>
    <ID>001</ID>
    <公司>A 公司</公司>
    <EMAIL>zhang@some.com</EMAIL>
    <电话>(1234) 456789</电话>
    <地址>
      <街道>五街 1234 号</街道>
      <城市>福州市</城市>
      <省份>福建</省份>
      <ZIP>350001</ZIP>
    </地址>
  </联系人>
</联系人列表>
```

XML 的优点

- 自我描述语言
 - 便于人类和机器理解
 - 遵循严格的语法要求
-
- 与 HTML 不同， XML 让你可以定义自己的标记！

(Extensible!)



XML 文件的组成

XML 文件的组成

- XML 声明
- 元素
- 属性
- 实体
- CDATA
- 注释

```
<?xml version = "1.0"?>  
<小纸条>  
  <收件人>张三</收件人>  
  <发件人>李四</发件人>  
  <主题>问候</主题>  
  <具体内容>最近可好? </具体内容>  
</小纸条>
```

XML 声明

- 一个最简单的 XML 声明是这样的：

```
<?xml version="1.0"?>
```

- 声明中还有两个**可选**属性，分别是“standalone” 和 “encoding”

```
<?xml version = "1.0"  
       standalone = "yes"  
       encoding = "UTF-8"?>
```

XML 元素

- 元素是 XML 文件内容的基本单元
- 一个元素包含一个起始标记、一个结束标记以及标记之间的数据内容
- 其形式是：<标记>数据内容</标记>
- 例如： <姓名>张三</姓名>

标记

- 所有 “<” 和 “>” 之间的内容都称为标记
- 要求：
 - 标记名必不可少
 - 大小写有所区分
 - 要有正确的结束标记 <tag></tag>
 - 标记要正确嵌套 <a>

XML 根元素/正确嵌套

```
<?xml version="1.0" encoding="UTF-8" ?>
<联系人列表>
    <联系人>
        <姓名>张三</姓名>
        <ID>001</ID>
        <公司>A 公司</公司>
        <EMAIL>zhang@some.com</EMAIL>
        <电话>(1234) 456789</电话>
        <地址>
            <街道>五街 1234 号</街道>
            <城市>福州市</城市>
            <省份>福建</省份>
            <ZIP>350001</ZIP>
        </地址>
    </联系人>
</联系人列表>
```

```
graph TD
    Root[<?xml version="1.0" encoding="UTF-8" ?>
<联系人列表>] <--> EndRoot[</联系人列表>]
    Contact[<联系人>] <--> EndContact[</联系人>]
    Address[<地址>] <--> EndAddress[</地址>]
```

合法的标记命名 lexical rule

- 以字母、下划线 “_”或冒号 “：“ 开头
 - 后面跟随字母、数字、句号 “.”、冒号、下划线或连字符 “-”，**但是中间不能有空格**
 - 而且任何标记名不能以 “**xml**” 开头！
-
- 另外，最好不要在标记的开头使用**冒号**，尽管它是合法的，但可能会带来混淆

属性 attribute

- 标记可以拥有属性，使得标记在描述信息时更加灵活 <标记名 (属性名 = "属性取值") * >

```
<圆柱体 半径="10" 高="13">
```

- 注意：
 - 属性必须用**双引号**标记起来
 - 属性的值都被 XML 处理程序看作是字符串处理

字符数据

- 在 XML 中，起始和结束标记之间出现的所有合法字符都被忠实地传给 XML 处理程序

(1)

```
<格式>一段文字</格式>
```

(2)

```
<格式>  
一段文字  
</格式>
```

实体引用

- 为了避免把字符数据和标记中需要用到的一些特殊符号相混淆，XML 还提供了一些有用的实体引用替代数据中的特殊符号

字符	实体引用
<	<
>	>
&	&
"	"

实体引用

- 如果我们在“示例”这个标记中出现文本

```
<姓名>张三</姓名>
```

- 正确的写法是：

```
<示例>&lt;姓名&gt;张三&lt;/姓名&gt;</示例>
```

CDATA

- 在一个特殊的标记 CDATA 下，所有的标记、实体引用都被忽略，而被 XML 处理程序一视同仁地当作字符数据看待
- CDATA 的形式如下：



CDATA Sample

<示例>

```
<![[CDATA[<联系人>
    <姓名>张三</姓名>
    <EMAIL>zhang@s.com</EMAIL>
</联系人>
]]>
</示例>
```

注释

- XML 中注释是用 “`<!--`”和 “`-->`”引起的字符串

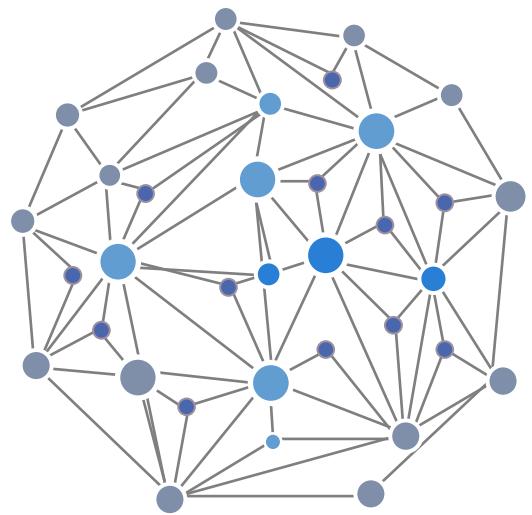
<示例>

```
<!-- 一个XML 的例子 -->
```

.....

注释的注意事项

- 在注释文本中不能出现字符 “-” 或字符串
“--”
- 不要把注释文本放在标记之中
- 不要把注释文本放在实体声明中，也不要
放在 XML 声明之前
- 注释不能被嵌套



文档类型定义 DTD

Document Type Definition

形式良好 (Well-formed) XML 文件

- 所谓 “**形式良好**” 有着明确的标准，就是要**遵守 XML 规范中的语法规则**
 - 所有的标记都要正确的嵌套
 - 只有一个根元素
 - ...
- 如何检查是否形式良好?
 - 用浏览器 (IE, Firefox etc.)
 - Eclipse, Visual Studio 等工具

如何检查是否形式良好?

The screenshot shows two windows side-by-side. On the left is a Microsoft Internet Explorer window titled 'G:\Work\Web程序设计\2005软件工程专业\experiments\exp1\MS-Validator\sample4.xml - Microsoft Internet Explorer'. It displays an error message: '无法显示 XML 页。' (Cannot display XML page.) and '使用 XSL 样式表无法查看 XML 输入。请更正错误然后单击 刷新 按钮，或以后重试。' (Using an XSL style sheet cannot view the XML input. Please correct the error and click the Refresh button, or try again later.) Below this is a detailed error log:

结束标记‘联系人’与开始标记‘姓名’不匹配。处理资源
'file:///G:/Work/Web程序设计/2005软件工程专
业/experiments/exp1/MS-Validator/sample4.xml' 时出错。第
17 行...

</联系人>
----^

On the right is a Microsoft XML Editor window titled 'G:\Work\Web程序设计\2005软件工程专业\experiments\exp1\MS-Validator\sample4.xml'. It shows the XML code with syntax highlighting and some nodes selected:

```
<?xml version="1.0" encoding="GB2312"?>
<!DOCTYPE 联系人列表
          SYSTEM "fc1ml.dtd">
<联系人列表>
    <联系人>
        <姓名>张三
        <ID>001</ID>
        <公司>A 公司</公司>
        <EMAIL>zhang@some.com</EMAIL>
        <电话>(123) 456789</电话>
        <地址>
            <街道>五街 1234 号</街道>
            <城市>福州市</城市>
            <省份>福建</省份>
            <ZIP>350001</ZIP>
        </地址>
    </联系人>
    <联系人>
        <姓名>李四</姓名>
        <ID>002</ID>
        <公司>B 公司</公司>
        <EMAIL>li@other.org</EMAIL>
        <电话>(021) 87654321</电话>
        <地址>
```

有问题的例子

```
<?xml version="1.0" encoding="UTF-8"?>

<联系人>
    <联系人列表>
        <姓名>张三</姓名>
        <公司>A 公司</公司>
    </联系人列表>
    <电话>(123)456789</电话>
</联系人>
```

“有效” (Valid) 的 XML 文件

- 一个 XML 文件除了应该是 “形式良好”的外，还应该是 “**有效**” 使用了自定义标记的 XML 文件
- 所谓 “有效” 的 XML 文件也就是你的自定义标记必须遵循特定的使用规则（可以是你制定的，也可以是国际组织制定的）

文档类型定义 DTD

- DTD (Document Type Definition) 描述了一个置标语言的语法和词汇表，也就是定义了文件的整体结构以及文件的语法

```
<?xml version = "1.0" encoding="UTF-8"  
standalone = "yes"?>  
<!DOCTYPE 根元素名[  
    元素描述  
]>  
文件体.....
```

DTD Sample

```
<?xml version="1.0" encoding="UTF-8"?>
```

```
<!DOCTYPE 联系人列表 [
```

```
    <!ELEMENT 联系人列表 (联系人)*>
```

```
    <!ELEMENT 联系人 (姓名, 公司, 电话)>
```

```
    <!ELEMENT 姓名 (#PCDATA)>
```

```
    <!ELEMENT 公司 (#PCDATA)>
```

```
    <!ELEMENT 电话 (#PCDATA)>
```

```
]>
```

```
<联系人列表>
```

```
    <联系人>
```

```
        <姓名>张三</姓名>
```

```
        <公司>A 公司</公司>
```

```
        <电话>(123)456789</电话>
```

```
    </联系人>
```

```
</联系人列表>
```

} DTD

外部 DTD

- 可以将 DTD 独立成一个文件，供多个 XML 引用
- 外部 DTD 常用于引用作者自己编写的 DTD

```
<!DOCTYPE 根元素名  
        SYSTEM "外部 DTD 文件的URL">
```

公用 DTD

- 还存在一种外部 DTD，它是一个由权威机构制订的，提供给特定行业或公众使用的 DTD
- 因此，另一个引用外部 DTD 的办法是使用关键字 **PUBLIC**，引用这一类公开给公众使用的 DTD

公用 DTD

- 引用公共DTD 的形式为：

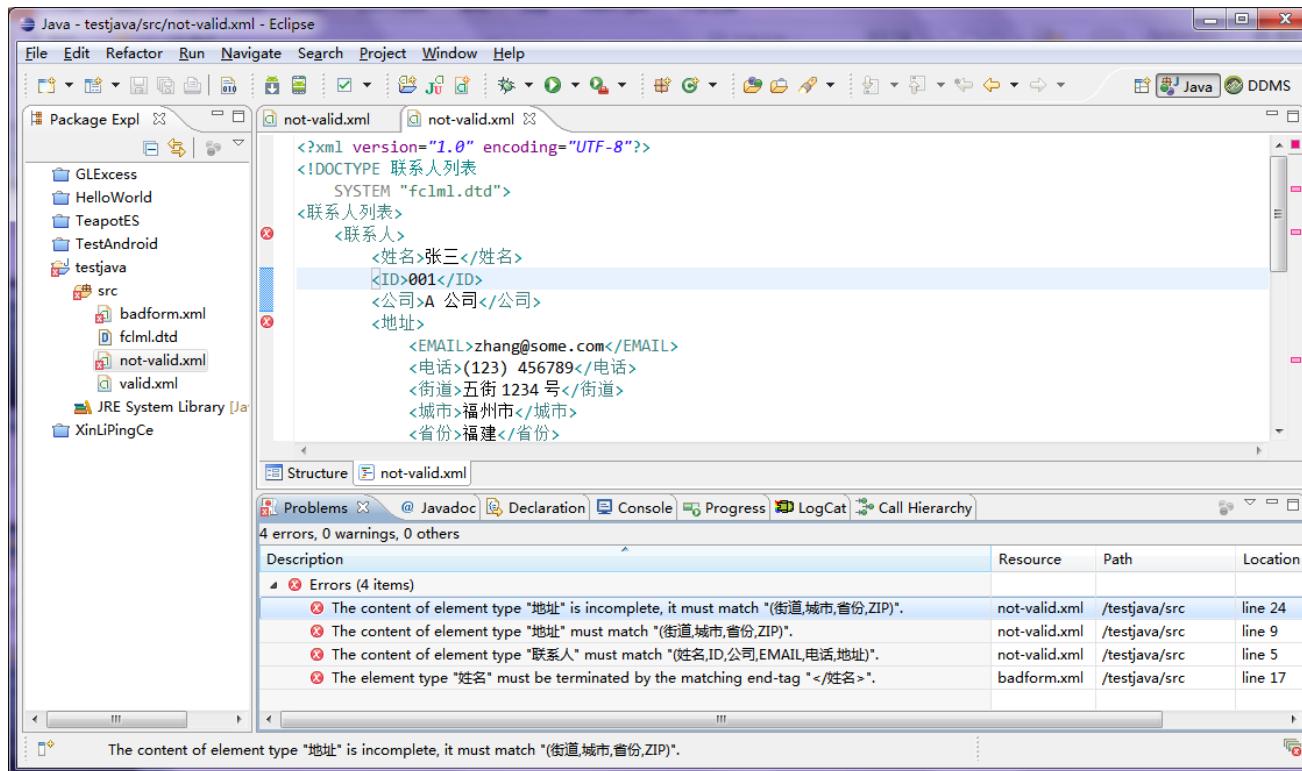
```
<!DOCTYPE 根元素  
        PUBLIC "DTD 名称" "公用 DTD 的URL">
```

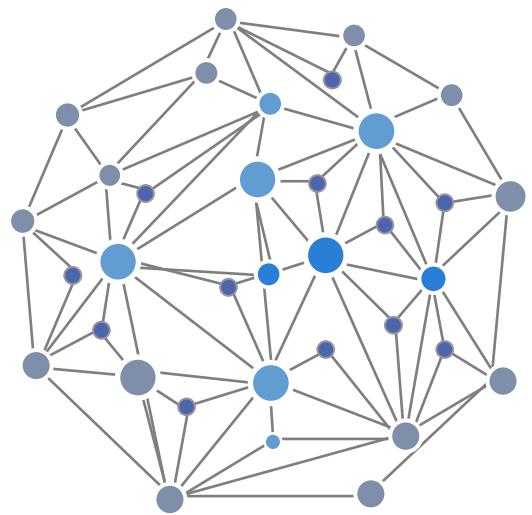
- 例如：

```
<!DOCTYPE 联系人列表 PUBLIC "联系人DTD"  
        "http://www.domain.com/dtds/clml.dtd">
```

如何检查有效性?

- 利用XML验证工具检查 (XML validation tools), 有很多这类工具
 - Eclipse, NetBeans 等都带有这个功能





XML 命名空间

XML 命名空间 (Namespace)

- 如何在一个 XML 文档中，包含由多个 DTD 描述的元素？
- 不同 DTD 中可能定义了相同的标记名称，但是含义却是不同的
- 解决方法就是使用命名空间

XML 命名空间

- XML 解决方案：使用 “**唯一名称:元素名称**” 的形式
- 这个 “**唯一名称**” 就称为命名空间
- 技巧：使用 **URI** 来获得一个唯一的名称
- 例如：福州大学定义了一个 **student** 标记：
[http://www.fzu.edu.cn:student](http://www.fzu.edu.cn)

XML 命名空间

```
<student xmlns:FZUST="http://fzu.edu.cn">
  <FZUST:stuno>220200xxx</FZUST:stuno>
  <FZUST:name>张三</FZUST:name>
  <FZUST:age>20</FZUST:age>
</student>
```

为何用 XML 做网页没有普及？

- 既然 XML 这么好，为何我们很少见过用 XML 做的网页？？？
- 优点有很多，但是一套自定义标记就是一种语言，开发效率低下，开发代码复杂

下一讲预告

解决之道： XHTML & HTML5

用 XML 重新定义HTML

第三讲课后练习

- 学习
 - <https://www.w3school.com.cn/xml/>
- 辅助阅读
 - XML中国论坛《XML初学进阶》前3章
 - 劳虎&胭脂虎 《无废话XML》第1,2,5,8章
- 电子书到课件所在的群文件下载

第三讲课后练习

- 编程作业 hw1
 - <https://chenyv.gitee.io/webprogramming/homeworks/xml/index.html>
 - 提交课程中心 met2.fzu.edu.cn
- 了解字符集和编码的基础知识
 - <https://www.cnblogs.com/skynet/archive/2011/05/03/2035105.html>
 - 《无废话XML》第三章

THANKS

本章结束

福州大学 计算机与大数据学院 软件工程系

